

Predicción de Comportamiento de Compra

Proyecto de Machine Learning aplicado al análisis de datos de clientes

Integrantes:

- Julian Gómez Posada
- Laura Muñoz Posada
- Samuel Gil Lopez

¿Qué problema abordamos?



Entender al cliente

Analizar patrones de compra para predecir comportamiento futuro



Mejorar decisiones

Usar datos para optimizar estrategias comerciales y marketing



Maximizar ventas

Identificar oportunidades de descuentos y montos de compra

El análisis de datos permite tomar decisiones más inteligentes en el mundo comercial.

Descripción del Dataset

El conjunto de datos registra el comportamiento de compra de los clientes en función de diferentes características demográficas y atributos de compra. Incluye información sobre los artículos comprados, el gasto, los antecedentes del cliente y sus preferencias de compra. Los datos ayudan a analizar las tendencias de consumo, los patrones de compra y el comportamiento estacional.

El dataset tiene un total de 3900 filas, 18 columnas y 0 nulls





- | | | |
|---|---|---|
| 1. ID de cliente (int): identificador único para cada cliente. | 1. Talla (objet): Talla de la prenda/calzado comprado. | 1. Descuento aplicado (objet): si se aplicó algún descuento. |
| 2. Edad (int): Edad del cliente en años. | 2. Color (objet): Color del artículo comprado. | 2. Código promocional utilizado (objet) : Indica si se aplicó algún código promocional. |
| 3. Género (objet): Indica si el cliente es masculino o femenino. | 3. Temporada (objet): Temporada en la que se realizó la compra. | 3. Compras anteriores (int) : número de compras históricas realizadas por el cliente. |
| 4. Artículo comprado (objet): El producto específico que compró el cliente. | 4. Calificación de la reseña (float): Calificación numérica que el cliente otorga a su experiencia de compra. | 4. Método de pago (objet) : modo de pago utilizado para la transacción. |
| 5. Categoría (objet): Categoría de producto como ropa, calzado, etc. | 5. Estado de la suscripción (objet) : indica si el cliente está suscrito (Sí/No). | 5. Frecuencia de compra (objet) : con qué frecuencia el cliente realiza compras. |
| 6. Importe de la compra (USD) (int) : importe total gastado en dólares estadounidenses. | 6. Tipo de envío (objet): método utilizado para enviar el pedido. | |
| 7. Ubicación (objet): Indique dónde realizó la compra el cliente. | | |

	Customer ID	Age	Gender	Item Purchased	Category	Purchase Amount (USD)	Location	Size	Color	Season	Review Rating	Subscription Status	Shipping Type	Discount Applied	Promo Code Used	Previous Purchases	Payment Method	Frequency of Purchases
0	1	55	Male	Blouse	Clothing	53	Kentucky	L	Gray	Winter	3.1	Yes	Express	Yes	Yes	14	Venmo	Fortnightly
1	2	19	Male	Sweater	Clothing	64	Maine	L	Maroon	Winter	3.1	Yes	Express	Yes	Yes	2	Cash	Fortnightly
2	3	50	Male	Jeans	Clothing	73	Massachusetts	S	Maroon	Spring	3.1	Yes	Free Shipping	Yes	Yes	23	Credit Card	Weekly
3	4	21	Male	Sandals	Footwear	90	Rhode Island	M	Maroon	Spring	3.5	Yes	Next Day Air	Yes	Yes	49	PayPal	Weekly
4	5	45	Male	Blouse	Clothing	49	Oregon	M	Turquoise	Spring	2.7	Yes	Free Shipping	Yes	Yes	31	PayPal	Annually






- **Items comprados** (valores unicos): 'Blouse', 'Sweater', 'Jeans', 'Sandals', 'Sneakers', 'Shirt', 'Shorts', 'Coat', 'Handbag', 'Shoes', 'Dress', 'Skirt', 'Sunglasses', 'Pants', 'Jacket', 'Hoodie', 'Jewelry', 'T-shirt', 'Scarf', 'Hat', 'Socks', 'Backpack', 'Belt', 'Boots', 'Gloves'
- **Localizaciones** (valores unicos): 'Kentucky', 'Maine', 'Massachusetts', 'Rhode Island', 'Oregon', 'Wyoming', 'Montana', 'Louisiana', 'West Virginia', 'Missouri', 'Arkansas', 'Hawaii', 'Delaware', 'New Hampshire', 'New York', 'Alabama', 'Mississippi', 'North Carolina', 'California', 'Oklahoma', 'Florida', 'Texas', 'Nevada', 'Kansas', 'Colorado', 'North Dakota', 'Illinois', 'Indiana', 'Arizona', 'Alaska', 'Tennessee', 'Ohio', 'New Jersey', 'Maryland', 'Vermont', 'New Mexico', 'South Carolina', 'Idaho', 'Pennsylvania', 'Connecticut', 'Utah', 'Virginia', 'Georgia', 'Nebraska', 'Iowa', 'South Dakota', 'Minnesota', 'Washington', 'Wisconsin', 'Michigan'

- **Tallas** (valores unicos): 'L', 'S', 'M', 'XL'
- **Colores** (valores unicos): 'Gray', 'Maroon', 'Turquoise', 'White', 'Charcoal', 'Silver', 'Pink', 'Purple', 'Olive', 'Gold', 'Violet', 'Teal', 'Lavender', 'Black', 'Green', 'Peach', 'Red', 'Cyan', 'Brown', 'Beige', 'Orange', 'Indigo', 'Yellow', 'Magenta', 'Blue'
- **Temporadas** (valores unicos): 'Winter', 'Spring', 'Summer', 'Fall'
- **Metodos de pago** (valores unicos): 'Venmo', 'Cash', 'Credit Card', 'PayPal', 'Bank Transfer', 'Debit Card'
- **Frecuencia de compra** (valores unicos): 'Fortnightly', 'Weekly', 'Annually', 'Quarterly', 'Bi-Weekly', 'Monthly', 'Every 3 Months'
- **Categorias de producto** (valores unicos): 'Clothing', 'Footwear', 'Outerwear', 'Accessories'



Analisis grafico de variables numericas



Variables categoricas



Correlaciones



Objetivos del Proyecto



Predicción de monto

Modelo de regresión para estimar el valor de compra



Predicción de descuento

Clasificación para determinar si se aplica descuento



Comparar diferentes modelos

Preparación de los datos

NO usamos:

- Item Purchased (demasiadas categorías)
- Location (50 estados → ruido)
- Color (demasiadas categorías)

Usamos:

- Category (4 valores)
- Season (4 valores)
- Size (4 valores)
- Gender
- Subscription Status
- Payment Method
- Frequency of Purchases

Encoding inteligente (no abusar de OneHot)

- Variables con pocas categorías → OneHot
- Variables ordinales → Label Encoding

Escalado

- KNN → necesita escala
- Regresión y Naive Bayes → no obligatorio

Modelos Utilizados



Regresión Lineal

Establece relación entre variables para predecir valores continuos como el monto de compra.



KNN (K-Nearest Neighbors)

Clasifica basándose en los datos más similares cercanos al caso nuevo.



Regresión Logística


Predice probabilidades de eventos binarios, ideal para clasificar si hay descuento o no.



Naive Bayes


Aplica teorema de Bayes asumiendo independencia entre características para clasificación rápida.

Regresión Lineal




Intento 1: Regresión Lineal Simple

- `test_size=0.2`
- $RMSE \approx 23.77$: Esta métrica nos dice que, en promedio, las predicciones del modelo se desvían alrededor de \$23.77 del valor, indicando que las predicciones del modelo son bastante imprecisas.
- R^2 negativo: Aproximadamente **-0.0099**. Este es el resultado más crítico. , nuestro modelo no explica casi nada de la variabilidad en el **Purchase Amount (USD)** y, de hecho



Intento 2: Regresión "Mejorada" (Ridge con Feature Engineering)

- $RMSE \approx 23.78$:
- R^2 negativo: -0.0108
- crear nuevas (columnas) a partir de las existentes para darle al modelo más información buscando relaciones no lineales
 - **Age_squared**: La edad al cuadrado,
 - **Previous_Purchases_log**: transformación logarítmica para reducir el impacto de valores extremos y hacer la distribución más normal
 - **High_Reviewer**: Una variable binaria (0 o 1) que indica si la **Review Rating** es mayor a 4
 - **Parámetro** `alpha=10`: controla la fuerza de esta penalización al coeficiente de la variable ayudando a evitar que los coeficientes sean demasiado grandes



Random Forest

- $RMSE$: 24.290428295830267
- R^2 : -0.0544022409111889

Incluso un modelo no lineal como Random Forest no logra mejorar el desempeño.

Esto indica que:

El problema NO es el modelo, el problema es el dataset porque tiene: Variables demográficas, Variables de comportamiento, Pero NO tiene variables que realmente expliquen el gasto. El monto de compra parece comportarse de forma casi aleatoria respecto a las variables disponibles.

Cuadro de significancia

Review Rating → clientes más satisfechos tienden a gastar un poco más (pero débil)


Previous Purchases → experiencia influye ligeramente

Age → comportamiento de consumo varía con edad

PERO: Ninguna variable tiene suficiente poder explicativo



Conclusion Modelo de regresión lineal




Las variables disponibles no contienen suficiente información predictiva sobre el monto de compra.

El comportamiento del gasto no depende significativamente de las características incluidas en el dataset.

Es posible que factores externos no incluidos (como ingresos, contexto económico o intención de compra) sean determinantes.

Regresión logística




Intento 1: Perfecto?

Accuracy: 1.0

	precision	recall	f1-score	support
0	1.00	1.00	1.00	422
1	1.00	1.00	1.00	358

Un rendimiento perfecto como este **es muy inusual en problemas de Machine Learning del mundo real** y suele ser una señal de alerta, indicando uno de los siguientes escenarios:

- Fuga de datos (Data Leakage):** Esto ocurre cuando la información que el modelo intenta predecir ya está presente en las características de entrada.
- Problema Demasiado Simple:** La variable objetivo (Discount Applied) es extremadamente fácil de predecir con las características actuales.




Intento 2: Eliminando 'Promo Code Used'

Accuracy: 0.8064102564102564

	precision	recall	f1-score	support
0	0.76	0.93	0.84	422
1	0.89	0.66	0.76	358

El modelo presenta un buen desempeño general con una precisión del 81%. Sin embargo, se observa un desbalance en la capacidad de detección entre clases:

El modelo identifica correctamente la mayoría de los casos sin descuento. Presenta dificultades para detectar todos los casos donde sí se aplica descuento.



Intento 3: Logística Balanceada

Accuracy: 0.8038461538461539


	precision	recall	f1-score	support
0	0.79	0.86	0.83	422
1	0.82	0.73	0.77	358

Se ajustó el modelo para manejar desbalance de clases, priorizando la detección de eventos de interés (descuentos), lo que mejora la capacidad del modelo para identificar casos positivos.

Dependiendo del objetivo del negocio, podría priorizarse el recall sobre la precisión, especialmente si es más importante detectar todos los descuentos que evitar falsos positivos


Modelo KNN

- **Accuracy general: 0.77:** El modelo clasifica correctamente el 77% de las instancias en el conjunto de prueba.
- **Métricas para la Clase 0 (Sin descuento):**
 - **Precision: 0.75:** Cuando el modelo predice 'sin descuento', acierta el 75% de las veces.
 - **Recall: 0.85:** El modelo es capaz de identificar el 85% de todos los casos reales donde no se aplicó un descuento.
 - **F1-score: 0.80.**
- **Métricas para la Clase 1 (Con descuento):**
 - **Precision: 0.79:** Cuando el modelo predice 'con descuento', acierta el 79% de las veces.
 - **Recall: 0.67:** El modelo solo logra identificar el 67% de todos los casos reales donde sí se aplicó un descuento.
 - **F1-score: 0.73.**
 - **Macro Average y Weighted Average:** Ambas métricas promedio están alrededor de 0.76-0.77, lo que confirma un rendimiento global moderado, pero con la misma tendencia de detectar mejor la clase 0 que la clase 1



Modelo Naive Bayes


- **Accuracy general: 0.81:** El modelo clasifica correctamente el 81% de las instancias en el conjunto de prueba.
- **Métricas para la Clase 0 (Sin descuento - support=422):**
 - **Precision: 0.76:** Cuando el modelo predice 'sin descuento', acierta el 76% de las veces.
 - **Recall: 0.94:** El modelo es muy bueno identificando los casos reales donde no se aplicó un descuento, capturando el 94% de ellos.
 - **F1-score: 0.84:**
- **Métricas para la Clase 1 (Con descuento - support=358):**
 - **Precision: 0.91:** Cuando el modelo predice 'con descuento', acierta el 91% de las veces. Esto es excelente, indicando pocos falsos positivos.
 - **Recall: 0.65:** Sin embargo, el modelo solo logra identificar el 65% de todos los casos reales donde sí se aplicó un descuento. Esto significa que hay bastantes falsos negativos para la clase 1 (casos donde se aplicó descuento pero el modelo predijo que no).
 - **F1-score: 0.76:**
- **Macro Average y Weighted Average:** Las métricas promedio están alrededor de 0.80-0.83, lo que indica un buen rendimiento general, pero la disparidad entre el recall de la clase 0 (0.94) y la clase 1 (0.65) es notable.



Comparación de modelos

	Modelo	Accuracy	Precision (Clase 1)	Recall (Clase 1)	F1-score (Clase 1)
0	Regresión Logística	0.81	0.89	0.66	0.76
1	KNN	0.77	0.79	0.67	0.73
2	Naive Bayes	0.81	0.91	0.65	0.76

- **Naive Bayes** es el modelo a elegir si tu prioridad es **asegurarte de que las predicciones de "descuento aplicado" sean lo más correctas posible** (alta precisión), incluso si eso significa no detectar algunos descuentos reales.
- La **Regresión Logística** proporciona un **rendimiento general muy sólido y equilibrado**, siendo una buena opción por defecto cuando no hay una prioridad clara entre precisión y recall para la clase minoritaria.
- **KNN** tuvo un desempeño ligeramente inferior en la mayoría de las métricas en esta configuración.



Contexto de uso en la vida real

Este modelo de Regresión Logística podría implementarse en un sistema de recomendación o en una plataforma de gestión de campañas de marketing. Por ejemplo:

- **Optimización de Campañas de Marketing:** Identificar segmentos de clientes que son más propensos a recibir un descuento, basándose en sus características, para personalizar ofertas y mejorar la eficiencia de las campañas.
- **Gestión de Inventario y Precios:** Predecir cuándo es más probable que los clientes utilicen descuentos para ajustar estrategias de precios o gestionar el stock de productos.
- **Análisis de Impacto:** Entender cómo cambios en variables como el tipo de envío, método de pago o frecuencia de compra influyen en la activación de descuentos, permitiendo a la empresa adaptar sus políticas.

Problemas Encontrados

Baja correlación

Las variables del dataset mostraron poca relación entre sí, dificultando las predicciones.

Data leakage

Se identificó información futura en los datos, corregido eliminando variables problemáticas.

Desafío del monto

Predecir el monto exacto de compra resultó más difícil que predecir descuentos.


Experimentación con KNN

Ajuste del parámetro K

Se probó con diferentes valores de K (número de vecinos cercanos) para optimizar el desempeño del modelo.

Impacto observado

El valor de K afectó significativamente el desempeño del modelo, demostrando la importancia de ajustar correctamente los hiperparámetros.



Experimento de quitar una variable y reducir tamaño de prueba

En este experimento, se realizaron dos cambios importantes en el modelo de Regresión Logística:

1. **Eliminar la variable 'Previous Purchases'** del conjunto de características.
2. **Modificar el tamaño del conjunto de prueba (test_size) a 0.003**. Esto significa que solo el 0.3% de los datos se usó para probar el modelo, dejando el 99.7% para el entrenamiento.

Cómo cambió el desempeño: La Accuracy del modelo se redujo a **0.75**.

la Regresión Logística original (sin balanceo de clases) había alcanzado una Accuracy de aproximadamente **0.81**. Por lo tanto, la eliminación de la variable y/o el cambio en el tamaño del conjunto de prueba han resultado en una disminución del rendimiento.

Predicción con Nuevo Caso

01

Crear cliente ficticio

Definir características como edad, género y comportamiento de compra

02

Aplicar modelos

Ejecutar cada modelo con el caso nuevo para obtener predicciones

03

Comparar resultados

Analizar diferencias entre predicciones de cada modelo

04

Interpretar

Entender qué modelo funciona mejor para ese tipo de cliente

Resultados

- **Regresión Logística:** Predijo **Descuento Aplicado**.
- **Naive Bayes:** Predijo **Sin Descuento**.
- **KNN (K=40):** Predijo **Descuento Aplicado**

Conclusiones

Mejor modelo

Regresión Logística mostró mejor desempeño para predicción de descuentos

Limitaciones

Baja correlación entre variables dificultó predicción de montos de compra

Mejoras futuras

Aplicar modelos más avanzados, como Random Forest o Gradient Boosting, especialmente para problemas no lineales.

El proyecto demostró la importancia de seleccionar el modelo adecuado y ajustar correctamente los datos para análisis de comportamiento de compra.